

LLM進度報告

2025/07/23

蔡承廷

評估RAG的四大指標

Context Precision (上下文精確度)：判斷從資料庫中拿出來的多少資料跟使用者的問題有關

問題：中國在哪裡，它的首都是什麼？

高上下文精確度答案：

中國位於亞洲，其首都是北京。北京以其現代建築以及紫禁城和天安門廣場等歷史遺址而聞名。中國遼闊的地貌包括草原、沙漠、山脈、湖泊、河流以及超過14,000公里的海岸線。北京城將現代與傳統建築風格相結合。

低上下文精確度答案：

位於亞洲的中國以北京為首都。北京有著像紫禁城這樣的古老文化遺址，也有現代的建築奇蹟。中國的地貌包括廣闊的草原、沙漠、山脈、湖泊、河流和漫長的海岸線。它擁有豐富的歷史和重要的文化遺址。

Context Recall (上下文召回率)：衡量模型有沒有把所有相關的資訊都從資料庫找出來

問題：中國在哪裡，它的首都是什麼？

標準答案：中國是一個位於亞洲的國家，其首都是北京。

高上下文召回率：中國位於亞洲，其遼闊的地貌包括草原、沙漠、山脈、湖泊、河流以及超過14,000公里的海岸線。其首都北京，以其現代建築以及紫禁城和天安門廣場等歷史遺址而聞名。

低上下文召回率：中國的地貌包括廣闊的草原、沙漠、山脈、湖泊、河流和漫長的海岸線。它擁有豐富的歷史和重要的文化遺址，位於亞洲。

評估RAG的四大指標

Faithfulness (忠實度)：LLM 的回答是否來源於從資料庫中找出來的資料

問題：愛因斯坦在哪裡、何時出生？

上下文：阿爾伯特·愛因斯坦（生於1879年3月14日）是一位德國出生的理論物理學家，被廣泛認為是有史以來最偉大、最有影響力的科學家之一。

高忠誠度答案：愛因斯坦於1879年3月14日在德國出生。

低忠誠度答案：愛因斯坦於1879年3月20日在德國出生。

Answer Relevance (回答相關性)：LLM 的回答有沒有跟問題有關

問題：法國在哪裡？首都是哪裡？

低相關性答案：法國在西歐。

高相關性答案：法國在西歐，首都是巴黎。

現在的RAG的策略-切分

第一步:讀取原始資料

- 系統讀取 power.json 等檔案，並自動識別出元件的「總類別」（如 motors, batteries）。
- 建立「父文件」

第二步:將每一個完整的元件 JSON 當作一個「父文件」。

- 給予每個父文件一個唯一的 doc_id（身分證）。
- 存入「父文件資料庫 (docstore)」。

第三步切割「子文件塊」

- 使用 RecursiveJsonSplitter 將完整的父文件內容，切分成多個語義相關的精簡區塊。

第四步建立關聯並索引

- 為每一個「子文件塊」都標記上其對應的父文件 doc_id。
- 將這些精簡的「子文件塊」轉換成向量，存入向量資料庫 (Vector DB) 以便快速搜尋。

現階段的RAG的策略-檢索&生成

第一步：查詢意圖分析

當使用者提出問題後，系統會先啟用一次 LLM，將自然語言轉換為結構化的 JSON 物件，例如 `{"component_type": "batteries", "keywords": "低溫環境 電池型號"}`。LLM 會被強制要求從 [可用類別列表] 中選擇一個最恰當的 type。如果 LLM 沒有很大的把握做出精準判斷，它的安全後備選項就是回傳 general。

第二步：硬性類別過濾

系統會拿著 JSON 中的 component_type，去遍歷資料庫中所有父文件的元數據，找出 component_type 完全一致的文件，並將它們加入一個「候選清單」。如果 type 是 general，則此過濾步驟會被跳過，所有父文件都會進入「候選清單」。

第三步：範圍內精準檢索與父文件回溯

系統會拿著 JSON 中的 keywords，在「候選清單」內的父文件所對應的所有子文件塊中，進行向量搜尋，找出最相關的 Top-K 個子文件塊（K值由 config.py 中的 RETRIEVER_TOP_K 設定，目前是 5）。然後，系統會根據這 Top-K 個子文件塊的元數據，回溯找到它們所屬的、完整的父文件，並將這些完整的父文件當作 LLM 的最終參考資料 (Context)。

第四步：通用模式 (General) 的處理流程

如果 type 是 general，系統會跳過第二步（硬性過濾），直接進入第三步（精準檢索）。但在這種情況下，第三步的搜尋範圍不再是過濾後的「候選清單」，而是資料庫中的全部文件。檢索器依然會盡力找出 Top-K 個最相似的子文件塊，並回溯到它們的父文件。正如您所說，這些檢索出的文件很可能與問題主題不完全相關，但最終會被最後一道防線——QA_TEMPLATE 提示詞中的嚴格規則——給擋掉，從而拒絕回答並承認資訊不足。

情境模擬:使用者提問：「根據低溫環境，知識庫中有推薦的電池型號嗎？」

第一步:[分析] 意圖分析

輸入：自然語言問題
處理：LLM 根據 QUERY_ANALYSIS_PROMPT 進行解析
輸出：結構化 JSON
JSON
{
 "component_type": "batteries",
 "keywords": "低溫環境 電池型號"
}

第三步:[檢索] 範圍內精準檢索

輸入：keywords: "低溫環境..." + 上一步的「候選清單」
處理：在候選清單的子文件塊中進行向量搜尋，命中溫度規格等區塊，並回溯父文件
輸出：最相關的完整父文件（例如 Top 3）
Tattu Pro 30000mAh (操作溫度 -20°C)
LongRanger 18650 Pack (環境溫度 -20°C)
FutureGen Solid-State (操作溫度 -20°C)

第二步:[過濾] 硬性類別過濾

輸入：component_type: "batteries"
處理：在父文件資料庫中進行元數據精確匹配
輸出：「候選清單」（共 5 個電池元件）
Graphene Panther 2200mAh 4S 75C
LongRanger 18650 Pack 8000mAh 6S
Tattu Pro 30000mAh 12S 5C
CNHL G+ 5200mAh 6S 50C
FutureGen Solid-State 1000Wh/kg Prototype

第四步:[生成] 高品質回答

輸入：上一步的 3 個完整父文件 + 原始問題
處理：LLM 根據 QA_TEMPLATE，在高品質、無污染的上下文中總結回答
輸出：有理有據的推薦列表
*推薦選項 1: Tattu Pro 30000mAh 12S 5C
* 摘要規格: 操作溫度: -20°C 至 60°C , 能量密度: 204.9 Wh/kg
推薦理由: 這款電池明確標示其最低操作溫度可達 -20°C，完全符合您的低溫環境需求...

可以使用的類別列表：

main_frame_arms (主機架臂)

wings (機翼)

landing_gears (起落架)

enclosures_covers (外殼/蓋子)

motors (馬達)

propellers (螺旋槳)

escs (電調)

batteries (電池)

imu (慣性測量單元)

gnss_receiver (全球導航衛星系統接收器)

rtk_ppk (即時動態/後處理動態)

cameras (相機)

gimbal_camera (雲台相機)

infrared (紅外線)

multispectral (多光譜)

flight_controller_firmware_software (飛控韌體/軟體)

wireless_communication_modules (無線通訊模組)

general (一般)